Assignment 1. Digital Signal Processing — Report

1. LogMelFilterBanks Implementation

Описание

Реализован PyTorch-слой `LogMelFilterBanks`, который извлекает логарифмы энергий мел-фильтров из сырого аудиосигнала.

Верификация

Сравнение с `torchaudio.transforms.MelSpectrogram` на тестовом сигнале (синусоида 440 Гц, 1 сек, 16 kHz):

```
melspec = torchaudio.transforms.MelSpectrogram(hop_length=160, n_mels=80)(signal)
logmelbanks = LogMelFilterBanks()(signal)
assert torch.log(melspec + 1e-6).shape == logmelbanks.shape   # Успешно
assert torch.allclose(torch.log(melspec + 1e-6), logmelbanks)  # Успешно
```

Визуальное сравнение

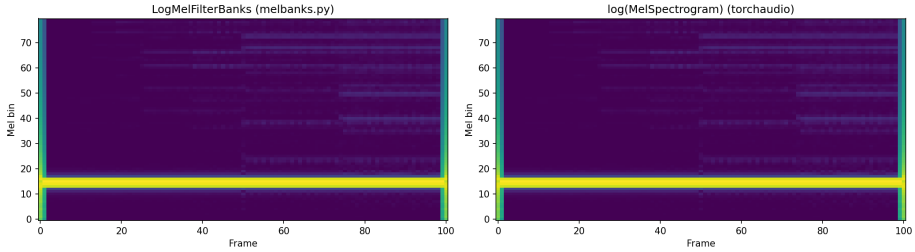

Figure 1: Сравнение LogMelFilterBanks с torchaudio

Графики идентичны, что подтверждает корректность реализации

---

2. Training Pipeline Setup

Датасет

Использован `torchaudio.datasets.SPEECHCOMMANDS`. Отфильтрованы только **“yes”** и **“no”** для бинарной классификации.

Split	Samples	yes	no
Training	6358	3228	3130
Validation	803	397	406
Testing	824	419	405

Все аудио приведены к длине 16000 отсчётов (1 сек) через padding нулями или обрезку.

Архитектура модели

Простая CNN на основе `Conv1d`:

```
LogMelFilterBanks -> Conv1d(n_mels, 64) + BN + ReLU + MaxPool
                  -> Conv1d(64, 64) + BN + ReLU + MaxPool
                  -> Conv1d(64, 32) + BN + ReLU
                  -> Global Average Pooling
                  -> Linear(32, 1)
```

Baseline (n_mels=80, groups=1): **34 305 параметров** — укладывается в ограничение 100K.

Обучение

- Optimizer: Adam, lr=1e-3
- Loss: BCEWithLogitsLoss
- Epochs: 10
- Batch size: 64

Подсчёт параметров и FLOPs

- Параметры: `sum(p.numel() for p in model.parameters())`
- FLOPs: библиотека thop

---

3. Эксперимент: n_mels

Обучены 3 модели с `n_mels in {20, 40, 80}`, `groups=1`.

n_mels	Parameters	Test Accuracy
20	22 785	0.9915
40	26 625	**0.9964**
80	34 305	0.9842

Train Loss

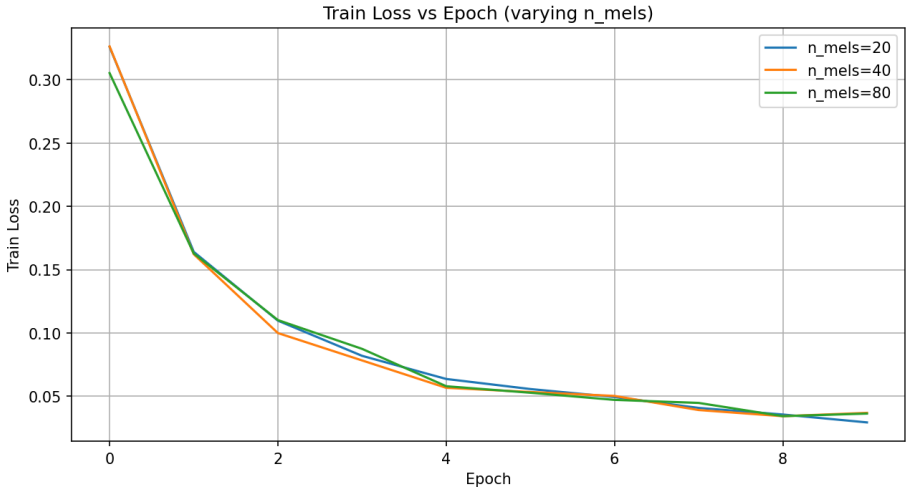

Figure 2: Train Loss vs n_mels

Все три варианта сходятся хорошо, loss монотонно уменьшается.

Test Accuracy

Выводы

- Лучший результат 99.64% у n_mels=40. Тут понятно, что больше фильтров не значит лучше.
- n_mels=20 даёт 99.15% — даже 20 фильтров достаточно для различения двух слов.
- n_mels=80 показал 98.42% — вероятно, модели с 34K параметрами не хватает ёмкости, чтобы эффективно использовать 80 каналов, и она слегка переобучается или хуже обобщает.
- Для бинарной задачи yes/no нет смысла брать много мел-фильтров. Оптимум — в районе 40.

Baseline для следующего эксперимента: n_mels=80 (чтобы `groups` делился нацело на количество каналов).

---

4. Эксперимент: groups

Обучены 5 моделей с `groups in {1, 2, 4, 8, 16}`, `n_mels=80`.

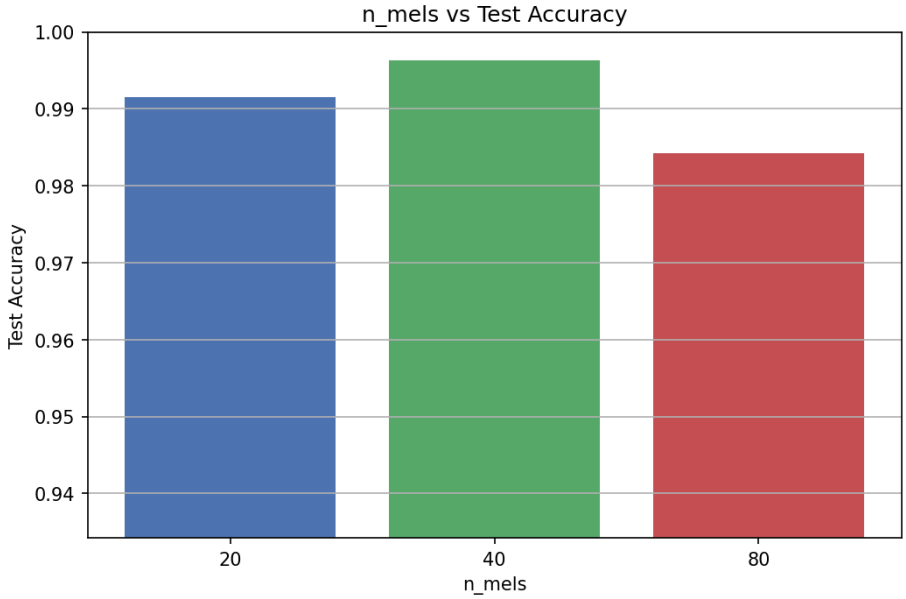

Figure 3: Test Accuracy vs n_mels

groups	Parameters	FLOPs	Avg Epoch Time (s)	Test Accuracy
1	34 305	2 361 248	11.7	0.9842
2	20 481	1 278 368	11.5	0.9745
4	13 569	736 928	11.8	0.9842
8	10 113	466 208	11.8	**0.9879**
16	8 385	330 848	11.8	0.9745

Метрики vs Groups

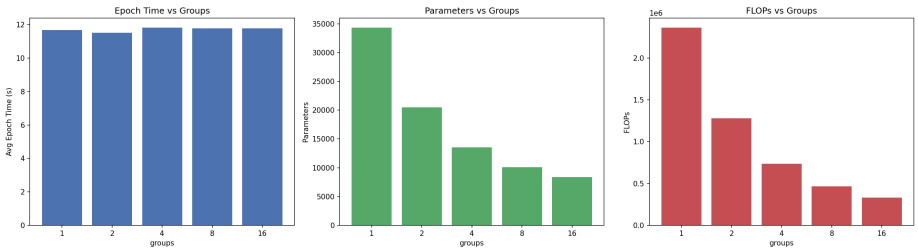

Figure 4: Groups metrics

Train Loss

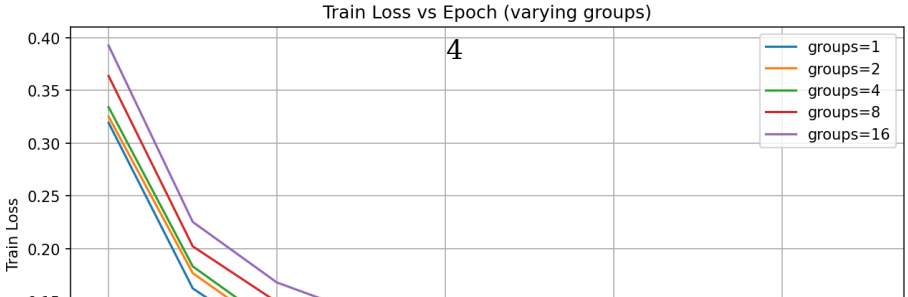

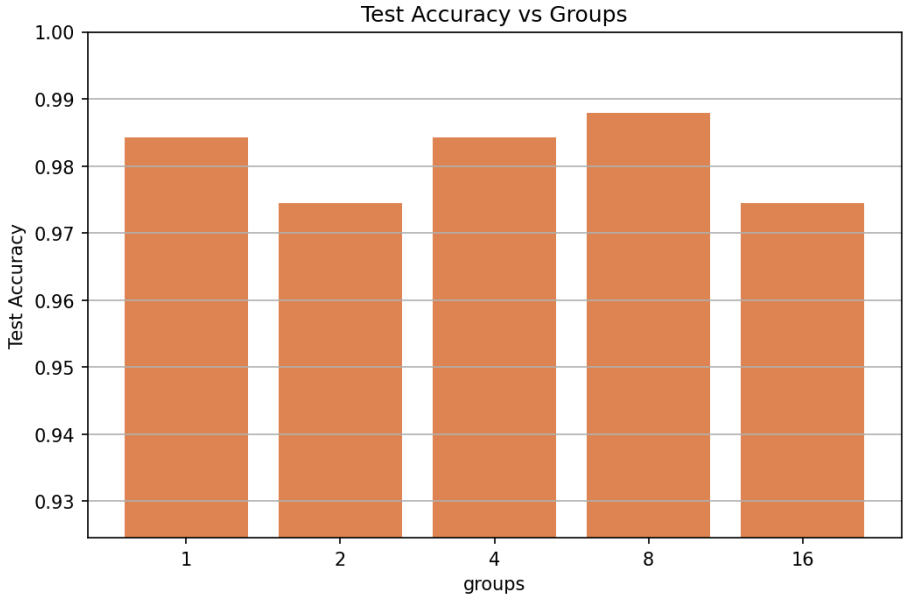

Figure 6: Test Accuracy vs groups

Test Accuracy

Выводы

- Параметры и FLOPs уменьшаются почти линейно с ростом groups. groups=16 даёт в 4 раза меньше параметров и в 7 раз меньше FLOPs по сравнению с groups=1.
- Epoch time практически не меняется (11.5–11.8 с). На CPU разница в FLOPs не даёт заметного ускорения, потому что рассходы от загрузки данных и мел-преобразования доминируют. На GPU разница была бы заметнее.
- Accuracy: groups=8 показал лучший результат (98.79%), что удивительно — с меньшим числом параметров модель обобщает лучше.
- groups=16 уже теряет в качестве (97.45%) — слишком мало связей между каналами, модель не может выучить достаточно сложные паттерны.
- Для простой бинарной задачи групповые свёртки — хороший выбор: можно сильно сократить модель без потери качества.

Все точные значения метрик и тд указаны в logs/log (на графиках

точность упразднена для меньшего визуального шума)