Assignment 2. Digital Signal Processing - Report

1. Greedy Decoding

Реализован жадный декодер, который на каждом временном шаге выбирает токен с максимальной вероятностью из лог-вероятностей, полученных после применения log_softmax к лог-маскам акустической модели. Затем выполняется сворачивание повторяющихся символов и удаление .

Method	WER (%)	CER (%)
Greedy	11.22	3.81

Референсные значения WER = 10.4%, CER = 3.5%.

Полученные метрики близки к референсным, что подтверждает корректность реализации жадного декодирования.

2. Beam Search Decoding

Реализован декодер на основе лучевого поиска. На каждом временном шаге хранятся beam_width наиболее вероятных гипотез. В конце каждой гипотезы выполнено сворачивание повторяющихся символов и удаление . Время выполнения измерено для всего тестового набора (200 аудио).

Beam width	WER (%)	CER (%)	Время (с)
1	11.24	3.80	53.7
3	11.15	3.78	67.8
10	11.07	3.77	110.9
50	11.10	3.77	447.0

Увеличение ширины луча с 1 до 10 снижает WER на 0.17% (с 11.24% до 11.07%) и CER на 0.03%.

При дальнейшем увеличении ширины до 50 качество практически не улучшается, но время выполнения возрастает в 4 раза по сравнению с шириной 10.

Наилучшее качество достигается при beam_width = 10. Дальнейшее увеличение луча нецелесообразно из-за резкого роста вычислительных затрат.

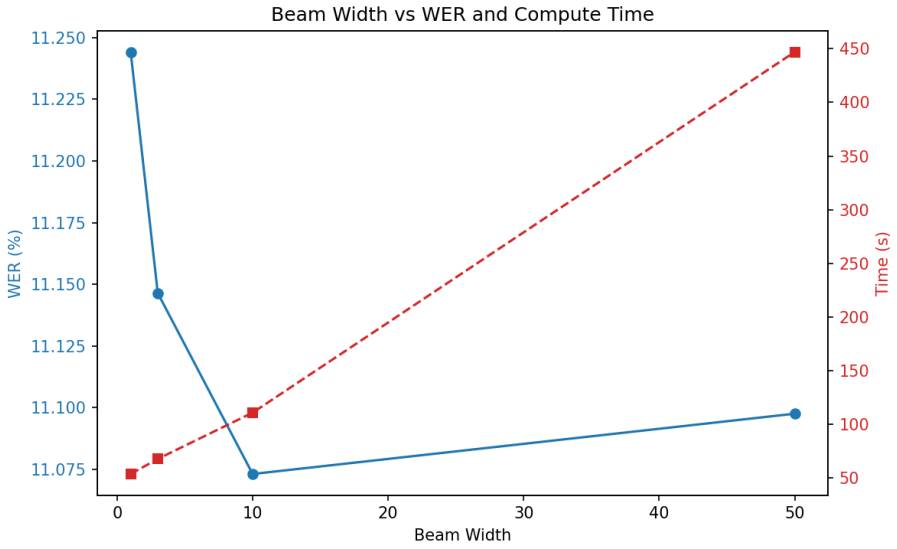

Figure 1: Результаты в зависимости от ширины луча

3. Temperature scaling

Применена температурная нормализация лог-вероятностей. Исследовано влияние температуры на жадное декодирование. Ожидалось, что изменение температуры изменит распределение вероятностей и повлияет на качество распознавания.

Temperature T	WER (%)	CER (%)
0.5	11.22	3.81
0.8	11.22	3.81
1.0	11.22	3.81
1.2	11.22	3.81
1.5	11.22	3.81
2.0	11.22	3.81

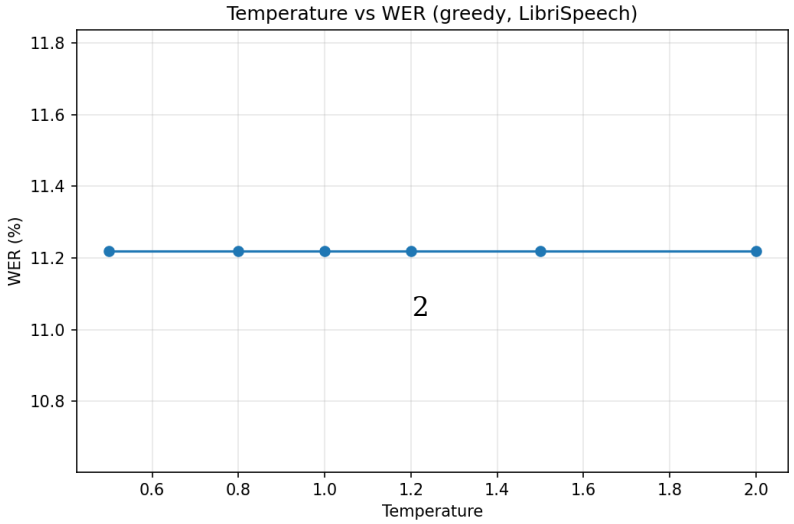

4. Shallow fusion

Реализована shallow fusion с предоставленной 3-gram KenLM моделью.

Сетка параметров: alpha in {0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0} beta in {0.0, 0.5, 1.0, 1.5}

Ширина луча фиксирована: beam_width = 10.

alpha \ beta	0.0	0.5	1.0	1.5
0.01	11.07	11.02	11.20	11.32
0.05	11.02	11.00	11.22	11.32
0.1	11.07	10.98	11.05	11.32
0.5	11.44	11.15	11.07	11.00
1.0	11.90	11.88	11.49	11.10
2.0	26.37	21.71	19.14	16.50
5.0	99.98	99.98	99.98	99.98

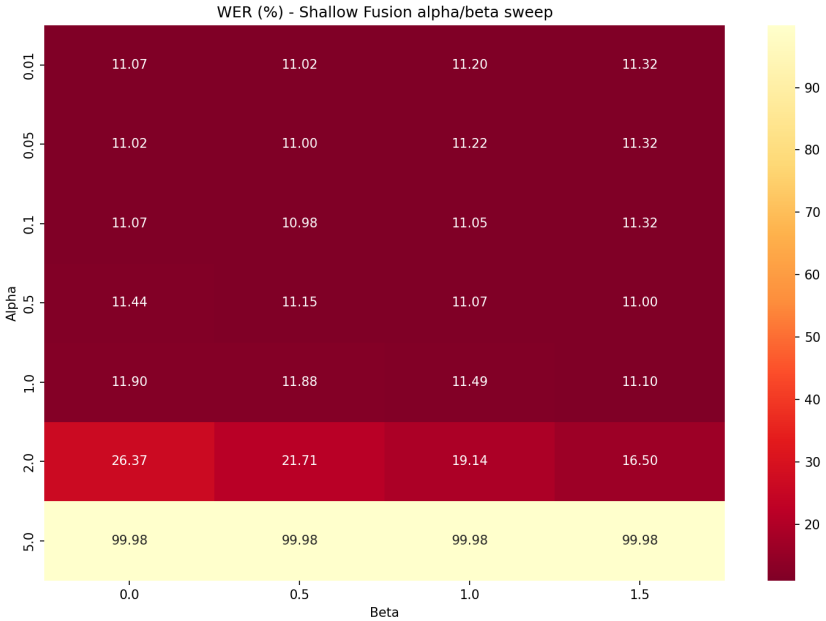

Figure 3: Результаты (WER %)

Наилучшая конфигурация alpha = 0.1, beta = 0.5 даёт WER = 10.98%, CER = 3.74%.

5. 4-gram LM

Загружена 4-gram LM и применен sf с параметрами, найденными для 3-gram в прошлой таске.

LM	WER (%)	CER (%)
3-gram	10.98	3.74
4-gram	11.02	3.75

Увеличение порядка LM с 3-gram до 4-gram не привело к улучшению качества. Напротив, WER незначительно вырос

6. LM rescoring

Реализован двухпроходный подход LM rescoring. На первом этапе выполняется beam search без языковой модели (beam_width = 10), формируется набор гипотез. На втором этапе каждая гипотеза пересчитывается с использованием языковой модели

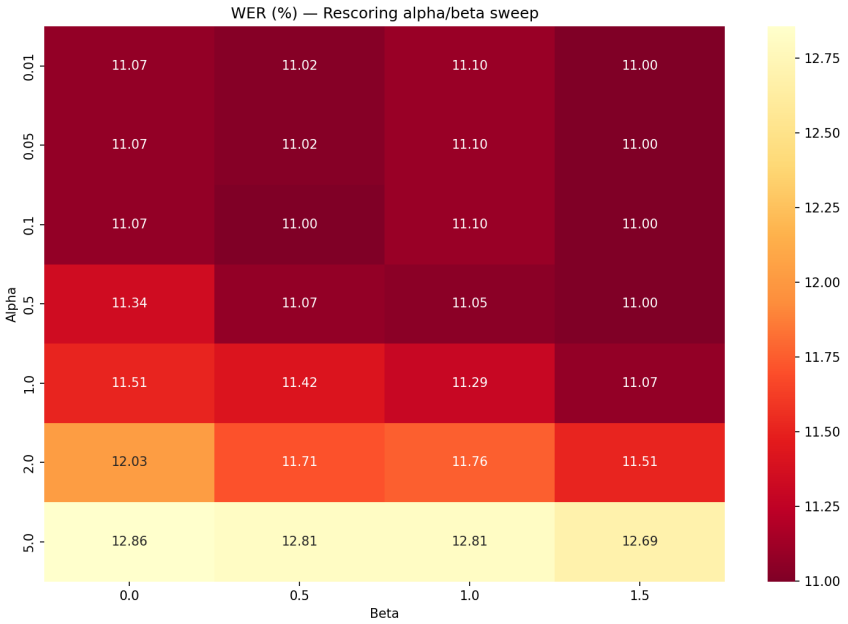

Figure 4: Результаты (WER, %)

alpha beta	0.0	0.5	1.0	1.5
0.01	11.07	11.02	11.10	11.00
0.05	11.07	11.02	11.10	11.00
0.1	11.07	11.00	11.10	11.00
0.5	11.34	11.07	11.05	11.00
1.0	11.51	11.42	11.29	11.07
2.0	12.03	11.71	11.76	11.51
5.0	12.86	12.81	12.81	12.69

Наилучшая конфигурация alpha = 0.01, beta = 1.5 даёт WER = 11.00%, CER = 3.74%.

Сравнение с sf из 4 таски

Метод	Лучший WER (%)	Устойчивость при alpha=5.0
Shallow fusion	10.98 (alpha=0.1, beta=0.5)	WER = 99.98% (полная деградация)
Rescoring	11.00 (alpha=0.01, beta=1.5)	WER = 12.69% (умеренное ухудшение)

Устойчивость к большим значениям alpha

При alpha=5.0 sf полностью разрушает качество (WER почти 100%), тогда как rescoring сохраняет приемлемый уровень (WER около 12%). Это объясняется тем, что в sf LM участвует в процессе поиска гипотез, и при высоком весе акустическая модель перестаёт влиять на формирование луча. В rescoring же гипотезы уже сформированы без LM, и даже при большом alpha пересчёт лишь меняет их порядок, но не отбрасывает акустически правдоподобные варианты

Далее идет качественный анализ транскрипций, вот примеры:

Пример 1:

REF: the kick he had received was a foretaste of what he might expect and after a little consideration he came to the conclusion that his duty was to escape and get back to the cutter as quickly as he could

BEAM: the kickhe had received was a foretaste of what he might expect and after a little consideration he came to the conclusion that his duty was to escape and get back to the cutter as quickly as he could

SF: the kickhe had received was a foretaste of what he might expect and after a little consideration he came to the conclusion that his duty was to escape and get back to the cutter as quickly as he could (correct)

RS: the kick he had received was a fore taste of what he might expect and after a little consideration he came to the conclusion that his duty was to escape and get back to the cutter as quickly as he could (correct)

Пример 2:

REF: a fellow who was shut up in prison for life might do it he said but not in a case like this

BEAM: a fellow who as shut up in prison for life might doit he said but not in a case like this

SF: a fellow who as shut up in prison for life might do it he said but not in a case like this (correct)

RS: a fellow who as shut up in prison for life might do it he said but not in a case like this (correct)

REF: stop here till sir risdon comes down and tell him i'm very sorry that we should have cleared out last night only a born fool saw jerry nandy's lobster boat coming into the cove and came running to say it was a party from the cutter yes father

Пример 3:

BEAM: stop here till sir rysdon comes down and tell him i'm very sorry that we shoul have cleared out last night only a born fool saw jerry nandy's lobsterboat coming into the cove and came running to say it was a party from the cutter yes father

SF: stop here till sir rysdon comes down and tell him i'm very sorry that we shoul have cleared out last night only a born fool saw jerry nandy's lobsterboat coming into the cove and came running to say it was a party from the cutter yes father (correct)

RS: stop here till sir rysdon comes down and tell him i'm very sorry that we shoul have cleared out last night only a born fool saw jerry nandy's lobster boat coming into the cove and came running to say it was a party from the cutter yes father (correct)

Пример 4:

REF: and why did andy call mister gurr father

BEAM: and why did andy call mister gurfather

SF: and why did andy call mister gur father (correct)

RS: and why did andy call mister gur father (correct)

Какие ошибки LM склонен исправлять?

1. Отсутствие пробелов между словами (слияние):
   - kickhe -> kick he (пример 1)
   - doit -> do it (пример 2)
   - gurfather -> gur father (пример 4)
2. Разделение составных слов:
   - lobsterboat -> lobster boat (пример 3)

Какие ошибки LM не исправляет или делает хуже?

1. Акустически похожие, но грамматически/лексически неверные слова
   - as вместо was (пример 2, 3)
   - rysdon вместо risdon (пример 3)
2. Опечатки
   - shoul вместо should (пример 3)
3. Внесение новых ошибок
   - В rescoring foretaste -> fore taste (пример 1)

Есть ли случаи, когда shallow fusion и rescoring расходятся?

SF: lobsterboat остаётся слитным (не исправлено)

RS: lobsterboat -> lobster boat (исправлено)

7. Оценка на out-of-domain

Применены лучшие конфигурации для каждого метода на тестовом наборе Earnings22

Method	LibriSpeech WER	LibriSpeech CER	Earnings22 WER	Earnings22 CER
Greedy	11.22	3.81	54.97	25.58
Beam search	11.07	3.77	54.94	25.38
SF	10.98	3.74	55.57	25.47
RS	11.00	3.74	55.33	25.38

На LibriSpeech WER составляет 11%, на Earnings22 55%. Разница более 44% абсолютного WER. CER также вырос с 3.7% до 25%.

Модель wav2vec2-base-100h обучена на LibriSpeech чистой, хорошо записанной книжной речи. Earnings22 содержит реальные финансовые конференц-звонки: фоновый шум, различные микрофоны, акценты, перебивания, неформальная речь. Акустическая модель не адаптирована к таким условиям.

Из таблицы видно, что shallow fusion и rescoring на Earnings22 не улучшают качество по сравнению с чистым beam search:

- SF даёт WER 55.57% (хуже, чем 54.94% у beam)
- RS даёт WER 55.33% (незначительно хуже)

LM обучена на домене, не соответствующем целевому. Вероятности, которые она присваивает финансовым терминам, близки к нулю, поэтому при sf такие гипотезы штрафуются.

Вывод: Для out-of-domain данных необходима либо файн тюнинг акустической модели, либо использование доменно-специфичной языковой модели

7b. Влияние температуры на out-of-domain

Проведён эксперимент с температурным масштабированием на тестовом наборе Earnings22.

T	Greedy	Shallow Fusion
0.5	54.97	55.18
1.0	54.97	55.57
1.5	54.97	56.60
2.0	54.97	58.40

1. Greedy decoding WER остаётся неизменным (54.97%) при всех значениях температуры, как уже ранее и было проверено
2. Shallow fusion С ростом температуры качество монотонно ухудшается. Лучший результат достигается при T = 0.5 (WER = 55.18%), худший при T = 2.0 (WER = 58.40%).

Вопросы из задания:

Помогает ли более высокая температура LM fusion на out-of-domain речи?

Нет. Рост температуры монотонно ухудшает WER shallow fusion на Earnings22. Повышение T делает распределение

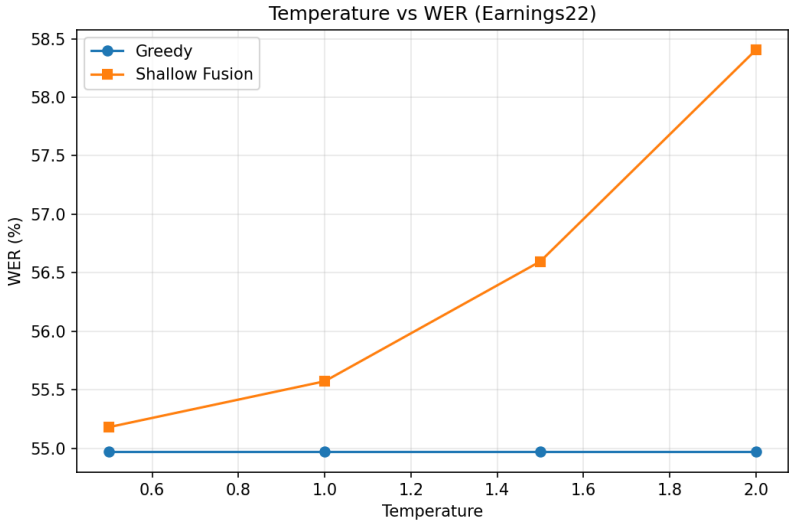

Figure 5: Результаты

акустической модели более равномерным, усиливая относительное влияние LM. Но LibriSpeech LM не знает финансовых терминов и её усиленное влияние только вредит.

Одинаково ли ведёт себя акустическая модель на LibriSpeech и Earnings22?

На LibriSpeech модель хорошо откалибрована: T = 1 оптимально, T > 1 только ухудшает результат. На Earnings22 акустическая модель не обучалась на финансовой речи и выдаёт неуверенные/неверные предсказания даже при T = 1. При этом снижение уверенности через T > 1 не помогает, так как LM тоже не подходит для этого домена и оба компонента ошибаются.

8. Финансовая языковая модель

Обучена 3-gram KenLM на корпусе `data/earnings22_train/corpus.txt`.

Сборка KenLM выполнена в Google Colab (на Arch Linux не удалось собрать из-за конфликтов зависимостей).

9. Сравнение LM на обоих доменах

Применены SF и RS с двумя LM (LibriSpeech 3-gram и финансовая 3-gram) на обоих тестовых наборах. Параметры лучшие из задач

4 и 6.

Domain	LM	Method	WER (%)	CER (%)
LibriSpeech	LibriSpeech-3gram	SF	10.98	3.74
LibriSpeech	LibriSpeech-3gram	RS	11.00	3.74
LibriSpeech	Financial-3gram	SF	10.95	3.77
LibriSpeech	Financial-3gram	RS	11.00	3.74
Earnings22	LibriSpeech-3gram	SF	55.57	25.47
Earnings22	LibriSpeech-3gram	RS	55.33	25.38
Earnings22	Financial-3gram	SF	52.56	25.12
Earnings22	Financial-3gram	RS	55.18	25.36

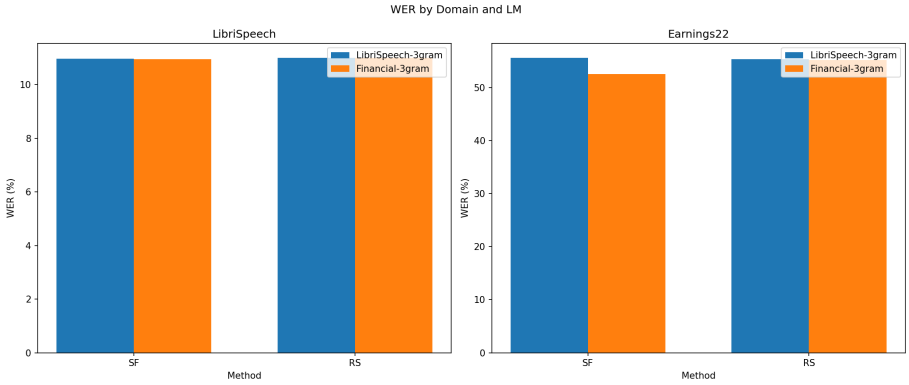

Figure 6: Сравнение WER/CER по доменам и LM

Какая LM лучше in-domain?

На LibriSpeech обе LM дают практически одинаковый результат (WER около 11%). Разница в пределах шума измерений.

Какая LM лучше out-of-domain?

На Earnings22 финансовая LM заметно улучшает SF. WER снижается с 55.57% до 52.56%. При rescoring улучшение меньше с 55.33% до 55.18%.

Доменноспецифичная vs. более крупная общая LM?

Финансовая 3-gram, обученная на примерно 100к слов, превзошла LibriSpeech 3-gram на финансовом домене. Доменное соответствие LM важнее её размера.

SF выигрывает от финансовой LM больше чем RS. При sf модель влияет на каждый шаг поиска и продвигает финансовые

термины с самого начала. При RS гипотезы уже сформированы без нужных слов и если слово не попало в beam, исправить это невозможно.